

HealthSearch

Arquitetura híbrida

Tendências em Ciência da Computação · UNIPÊ
Professor Me. Ricardo Roberto de Lima · 27/09/2026

1. Corpus e fluxo

Seis frases obrigatórias foram preservadas e ampliadas com IA em seis documentos de duas páginas, incorporados ao único arquivo `healthsearch_app.py`. O material da proposta anterior serve como corpus didático, sem finalidade clínica. As referências numeradas dos textos estão em `corpus/REFERENCIAS.md`.

BM25: documentos completos, tokens em minúsculas, sem acentos e stopwords. Hífens internos preservam identificadores como CÓD-ECG-12D. A biblioteca `rank_bm25` calcula o ranking; `k1` varia de 0 a 3 (padrão 1,2) e `b` de 0 a 1 (padrão 0,75). `k1=0` usa o limite binário para evitar 0/0.

Semântico: paraphrase-multilingual-MiniLM-L12-v2, 384 dimensões, execução real em CPU. Janelas respeitam o limite de tokens, com overlap de 24 tokens. O maior cosseno dos trechos define o score do documento; a passagem correspondente é exibida. Modelos e embeddings são armazenados em cache.

2. Fusão e interface

$RRF(D) = \alpha / (60 + \text{rank_BM25}) + (1 - \alpha) / (60 + \text{rank_semântico})$. Ranks iniciam em 1; empates usam ID crescente. α varia de 0 a 1 e inicia em 0,5. $\alpha=1$ conserva a ordem BM25; $\alpha=0$ conserva a semântica. A fusão combina posições, não os valores brutos incompatíveis.


Quatro abas: Léxico, Semântico, Híbrido RRF e Matriz Comparativa. Mostram scores, posições, parcelas da fusão, gráfico, exportação CSV e tempos. O bônus `mmarco-mMiniLMv2-L12-H384-v1` reordena apenas os Top-3 híbridos; seus logits não substituem nem representam probabilidades RRF.

3. Execução

Instale `requirements.txt` e execute `python -m streamlit run healthsearch_app.py`. O primeiro uso baixa pesos públicos; os seguintes reutilizam o cache. `python avaliar.py` recria os resultados e o gráfico. `python verificar_integracao.py` exercita os modelos reais e a interface.

Avaliação e limites

Parâmetros: $k1=1,2$; $b=0,75$; $\alpha=0,5$; constante $RRF=60$. Doze consultas exploratórias, sem seleção posterior de acertos. A referência é didática; a busca pelo código também é relevante ao Doc 6.



Acertos Top-1: BM25 10/12; semântico 10/12; híbrido 10/12. “Vigilância remota dos batimentos de paciente internado” leva Doc 6 de 3º no BM25 a 1º no híbrido. “P2Y12” leva Doc 2 de 2º no semântico a 1º no híbrido. Há complementaridade, sem superioridade global nesta amostra.

Contraexemplos: “o coração parou de bater e a pessoa não reage” coloca Doc 5 em 6º/1º/4º (BM25/semântico/RRF). “Derrame com início recente dos sintomas” coloca Doc 4 em 1º/2º/2º. A fusão pode piorar uma resposta; documentos com BM25 zero também recebem ranks conforme a fórmula exigida.

4. Verificação

Doze testes rápidos passaram. A integração com modelos reais confirmou parâmetros extremos, rankings finitos, extremos de α , Top-3 do bônus e controles Streamlit. Na busca pelo código, o bônus manteve Doc 1, Doc 6 e Doc 2, nessa ordem. Scores e evidências estão em resultados/; tempos do primeiro uso incluem aquecimento.

5. Responsabilidades

Distribuição proposta para apresentação e manutenção; não representa um histórico comprovado de autoria.

Arysson André Oliveira da Luz: corpus, pré-processamento e conferência dos dados. Luiz Henrique Monteiro dos Santos: interface, organização dos resultados e documentação. Paulo Victor Oliveira de Barros Araújo: mecanismos de ranking, integração e verificação dos cálculos.

Referências: enunciado Laboratório Prático 05; sbert.net; github.com/dorianbrown/rank_bm25; docs.streamlit.io. O corpus artificial e as consultas exploratórias não constituem validação clínica nem benchmark independente.